



Tópicos em Biotecnologia 2 · PPGBiotec / UFDPAr

Prof. Dr. Adonias Caetano de Oliveira

Avaliação de modelos de inteligência artificial na classificação de textos relacionados à saúde

Mapeamento topológico e classificação semântica de literatura biomédica

Raphael Di Giorgio
Aquiles Esaú da Silva Reis

9 de outubro de 2026

Resumo

Foram avaliadas cinco configurações de classificação de textos biomédicos: LinearSVC, Regressão Logística e k-NN sobre embeddings Sentence-BERT, além de Naive Bayes e LinearSVC sobre TF-IDF. A amostra contém os 10.000 primeiros pares pergunta-contexto de ruslanmv/ai-medical-dataset. Os alvos são sintéticos: cinco tópicos LDA e 18 comunidades de Louvain. Após undersampling, cada tarefa foi dividida em treino/teste estratificados 80/20; a validação cruzada de cinco folds foi restrita ao treino. O LinearSVC/TF-IDF obteve o maior F1 macro no teste LDA (0,8336), enquanto o k-NN/SBERT liderou a tarefa Louvain (0,7972). Na validação cruzada LDA, Naive Bayes/TF-IDF apresentou a maior média (0,8161), sem confirmação da mesma ordem observada no teste. Os resultados medem a reprodução de partições estatísticas, não correção clínica. Persistem limitações de avaliação transdutiva, pesos de distância no grafo, amostragem inicial não aleatória e duplicatas.

Tarefa	Classes	Treino / teste	Melhor F1 no teste
Macro: tópicos LDA	5	4.448 / 1.112	0,8336 · LinearSVC/TF-IDF
Micro: comunidades Louvain	18	2.419 / 605	0,7972 · k-NN/SBERT

Código: github.com/miscrapha-DELTA-IA/Projeto-de-PLN-Healthtec

Colab: [abrir a versão reproduzível do notebook](#).

Fonte dos resultados: pacote 20261009T051848409288Z.zip. Esta revisão utiliza uma única execução; as tabelas e figuras históricas A/B foram substituídas.

1. Entendimento do domínio

a) Qual problema de saúde o dataset representa?

Organização e recuperação de informação biomédica. Cada registro contém uma pergunta e um contexto de literatura sobre temas variados. O objetivo é agrupar e encaminhar textos por proximidade temática, permitindo explorar áreas de pesquisa e especialidades. Não se trata de um conjunto de prontuários rotulados para diagnóstico.

b) Qual é a tarefa e quantas classes são previstas?

Classificação supervisionada multiclasse, em duas tarefas complementares: cinco macroclasses provenientes do LDA e 18 microcomunidades provenientes do Louvain. Os dois classificadores fazem previsões independentes; não há uma restrição que imponha coerência hierárquica entre suas saídas.

c) Qual variável será prevista?

TARGET: tópico dominante do LDA, identificado como Tópico 0 a Tópico 4. Comunidade_Louvain: identificador da partição no grafo de embeddings, de 0 a 17 nesta execução. Ambos são rótulos derivados dos próprios textos, sem anotação clínica independente.

d) Qual é a utilidade prática?

Indexação temática, apoio à busca e revisão de literatura e exploração de nichos de pesquisa. A interface do notebook recebe um texto e retorna os dois rótulos com palavras-chave do perfil de comunidade. Uma eventual integração prática exige avaliação com usuários e validação externa.

e) Quem poderia utilizar o modelo?

Pesquisadores, bibliotecários biomédicos, gestores de informação científica e desenvolvedores de busca. O escopo é organização de literatura, com revisão humana, e não decisão clínica sobre pacientes.

f) Quais são as limitações e os riscos?

Os rótulos sintéticos podem ser coerentes estatisticamente sem representar categorias clínicas válidas. A amostra não aleatória e o balanceamento por descarte reduzem a representatividade. A escolha de distância como peso do grafo é metodologicamente questionável. Textos de teste participaram da formação dos rótulos, e foram encontrados dois pares textuais repetidos atravessando treino e teste LDA. A apresentação das métricas como acurácia diagnóstica seria inadequada.

2. Entendimento dos dados

a) Qual a dimensão utilizada?

10.000 registros, obtidos por streaming dos primeiros exemplos do split train, sem embaralhamento. A revisão da fonte está registrada no manifesto. Após o balanceamento, restaram 5.560 registros para LDA e 3.024 para Louvain. São subconjuntos distintos do mesmo corpus, não amostras independentes.

b) Quais são os atributos originais?

question contém a pergunta; context contém o trecho de literatura associado. A concatenação forma texto_bruto. As demais colunas são derivadas e estão detalhadas na página seguinte.

2. Entendimento dos dados — continuação

Atributo	Representação / finalidade
texto_bruto	question + context; entrada do SBERT.
texto_limpo	Minúsculas, letras, lemas e remoção de stopwords; entrada de LDA/TF-IDF.
embeddings	Vetor denso de 384 dimensões por texto.
TARGET / Comunidade_Louvain	Rótulos sintéticos das duas tarefas.
row_id	Identificador da linha original para auditar splits e folds.

c) Como está distribuída a variável-alvo?

Após undersampling, há 1.112 exemplos em cada um dos cinco tópicos LDA. Para Louvain, o manifesto registra as 18 comunidades abaixo antes do balanceamento; todas têm pelo menos 100 exemplos. Em seguida, cada uma foi reduzida a 168 registros.

ID	Textos no corpus	Palavras-chave do perfil TF-IDF
0	281	drug, nanoparticle, galectin, effect, protein
1	189	asthma, pulmonary, lung, airway, respiratory
2	893	care, patient, health, study, practice
3	353	diabete, thyroid, glucose, type, patient
4	1171	cell, expression, induce, effect, mir
5	574	patient, liver, cancer, disease, colorectal
6	387	pregnancy, maternal, woman, birth, infant
7	540	hiv, virus, infection, vaccine, hepatitis
8	963	patient, coronary, artery, cardiac, heart
9	320	prostate, patient, kidney, renal, cancer
10	453	infection, tuberculosis, sequence, strain, isolate
11	684	pain, patient, fracture, knee, study
12	288	eye, trial, treatment, patient, control
13	664	cancer, breast, cell, patient, tumor
14	914	brain, disorder, patient, depression, study
15	651	case, mutation, patient, syndrome, tumor
16	168	implant, tooth, dental, maxillary, bone
17	507	cell, cd, il, patient, immune

d-f) Balanceamento, redundância e observações da exploração

Louvain varia de 168 a 1.171 exemplos por comunidade (razão de aproximadamente 6,97:1); nenhuma comunidade foi descartada pelo limiar de 100. Pergunta e contexto podem repetir termos. O diagnóstico da amostra registrou sete pares question/context duplicados, quatro campos question vazios e quatro context vazios, sem nulos. Campos vazios não implicam necessariamente oito linhas distintas. Esses casos foram mantidos e constituem limitações.

3. Preparação dos dados

a) Quais procedimentos de limpeza foram aplicados?

Para LDA/TF-IDF: conversão para minúsculas, remoção por expressão regular de caracteres que não sejam letras ou espaços e descarte de tokens de um caractere. A limpeza remove números e pontuação e pode perder informação biomédica, como partes de nomes de genes, doses e códigos.

b) Como foram tratados nulos, vazios e duplicatas?

A pipeline agora verifica e registra esses casos. Não houve nulos em question/context. Os sete pares duplicados e os campos vazios foram mantidos para preservar o protocolo executado. Uma auditoria das divisões encontrou dois pares idênticos presentes em ambos os lados do split LDA e nenhum no split Louvain; IDs de linhas, por sua vez, são disjuntos. A deduplicação ou divisão por grupos de textos deve preceder uma futura avaliação.

c) Houve normalização textual?

O spaCy em_core_web_sm realiza lematização e remoção de stopwords, com parser e reconhecimento de entidades desativados. SBERT recebe texto_bruto, preservando contexto linguístico. Seu comprimento máximo registrado é 256 tokens; entradas mais longas podem ser truncadas, o que deve ser considerado ao interpretar o efeito do comprimento.

d) Como os textos foram representados?

Contagens com CountVectorizer para o LDA (max_features=1000, max_df=0,95, min_df=2); TF-IDF para Naive Bayes e LinearSVC (max_df=0,8, min_df=5); embeddings all-MiniLM-L6-v2 de 384 dimensões para os outros classificadores e o grafo. O TF-IDF dos classificadores está dentro de Pipeline e aprende vocabulário/pesos somente no treino de cada fold.

e) Houve seleção ou redução de atributos?

O vocabulário é limitado pelas regras de frequência acima. Os embeddings mantêm 384 dimensões; UMAP é apenas visualização e não é entrada dos classificadores. O TF-IDF que produz palavras-chave das comunidades é descritivo, ajustado ao corpus, e não deve ser confundido com o TF-IDF interno de cada classificador.

f) Como foi tratado o desbalanceamento?

Undersampling separadamente para cada alvo: $5 \times 1.112 = 5.560$ registros LDA; $18 \times 168 = 3.024$ Louvain. O filtro de comunidades menores que 100 permanece no código, mas não removeu nenhuma nesta execução. O balanceamento é de classes temáticas; não comprova equidade entre grupos demográficos.

g) Como foram definidos treino, teste e validação?

Divisão estratificada 80/20 com random_state=42. LDA: 4.448/1.112; Louvain: 2.419/605. A CV usa StratifiedKFold(n_splits=5, shuffle=True, random_state=42) somente sobre o treino. Todos os modelos recebem os mesmos IDs e folds em cada tarefa. Por arredondamento, os suportes do teste diferem por um exemplo entre classes; acurácia e recall macro são próximos, mas não necessariamente idênticos.

h) Como os rótulos foram preparados?

O LDA atribui a cada texto o tópico de maior probabilidade. Louvain atribui o ID da comunidade no grafo k-NN. Os IDs são categorias sem ordem e dependem da partição. LDA, grafo e Louvain foram ajustados no corpus completo antes do split: a CV não desfaz esse caráter transdutivo.

4. Modelagem

a) Quais modelos foram comparados?

Cinco configurações foram avaliadas para cada alvo, totalizando dez experimentos com avaliação no teste e 50 escores de validação cruzada.

Modelo / representação	Configuração principal
LinearSVC / SBERT e TF-IDF	C=1,0; max_iter=2000; tol=1e-4; dual=auto; random_state=42.
Regressão Logística / SBERT	C=1,0; solver=lbfgs; max_iter=2000; tol=1e-4; random_state=42.
k-NN / SBERT	k=10; distância cosseno; algorithm=brute; weights=uniform; n_jobs=1.
Naive Bayes / TF-IDF	MultinomialNB; alpha=1,0.
Geração do alvo LDA	5 componentes; learning_method=batch; max_iter=10; n_jobs=1; random_state=42.
Grafo / Louvain	k=10; distância cosseno como peso; resolution=1,0; random_state=42.

b) Por que essas abordagens?

LinearSVC é uma referência linear para texto; Regressão Logística oferece uma comparação linear probabilística; k-NN explora vizinhanças do espaço de embeddings; Naive Bayes é uma referência para representações esparsas. O par LinearSVC/SBERT e LinearSVC/TF-IDF permite examinar o efeito da representação mantendo a família do classificador.

c-d) Como as entradas e configurações foram definidas?

Três modelos recebem embeddings; dois recebem texto_limpo convertido por TF-IDF interno ao pipeline. Não houve busca de hiperparâmetros. Os parâmetros foram predefinidos, e o teste é usado para comparação descritiva, não para ajuste. Os tempos medidos incluem fit e predição de cada classificador/pipeline, excluindo preparação prévia e CV.

e) Como o Transformer foi utilizado?

all-MiniLM-L6-v2 foi usado como extrator congelado, sem fine-tuning. A revisão do modelo está fixada no manifesto. Os vetores foram produzidos em CPU, com batch_size=32, sem normalização explícita no encode, semente Torch 42 e algoritmos determinísticos habilitados.

f) Como os LLMs foram utilizados na classificação?

Não foram usados LLMs generativos como classificadores nem prompting zero-shot/few-shot. Esta afirmação se refere ao experimento de classificação; não descreve a assistência de IA utilizada no desenvolvimento e revisão dos materiais.

g-h) Implementação e condições de comparação

Python/Colab com scikit-learn, Sentence-Transformers, spaCy, NetworkX e python-louvain. Não foi utilizado Orange. As duas representações compartilham os mesmos exemplos de treino/teste e folds para cada alvo. A execução da comparação limita bibliotecas numéricas a uma thread e utiliza n_jobs=1. As versões e parâmetros completos constam no pacote.

5. Avaliação dos modelos

a) Quais métricas foram utilizadas?

Acurácia, precisão/recall/F1 macro, métricas por classe, matrizes de confusão e F1 macro em CV-5 (média $\pm$ desvio-padrão amostral, ddof=1). AUC não foi incluída porque o protocolo prioriza essas métricas multiclasse; a ausência de probabilidades no LinearSVC, isoladamente, não é justificativa suficiente para excluir todas as formulações de AUC.

5.1 Macro-áreas LDA — 5 classes; 1.112 exemplos de teste

Modelo	Acurácia	Precisão macro	Recall macro	F1 macro	CV-5 média $\pm$ DP	Treino (s)
LinearSVC TF-IDF	0,8336	0,8355	0,8337	0,8336	0,8091 $\pm$ 0,0062	1,049
Naive Bayes TF-IDF	0,8076	0,8107	0,8076	0,8069	0,8161 $\pm$ 0,0191	1,257
LinearSVC SBERT	0,7194	0,7201	0,7194	0,7194	0,6898 $\pm$ 0,0285	3,026
Reg. Logística SBERT	0,7131	0,7139	0,7131	0,7131	0,6996 $\pm$ 0,0190	1,731
k-NN SBERT	0,6466	0,6488	0,6466	0,6469	0,6304 $\pm$ 0,0108	0,012

5.2 Comunidades Louvain — 18 classes; 605 exemplos de teste

Modelo	Acurácia	Precisão macro	Recall macro	F1 macro	CV-5 média $\pm$ DP	Treino (s)
k-NN SBERT	0,8000	0,8055	0,8004	0,7972	0,7738 $\pm$ 0,0125	0,005
LinearSVC SBERT	0,7752	0,7755	0,7753	0,7729	0,7262 $\pm$ 0,0109	1,743
Reg. Logística SBERT	0,7471	0,7502	0,7474	0,7459	0,7458 $\pm$ 0,0168	0,360
LinearSVC TF-IDF	0,6595	0,6636	0,6599	0,6592	0,5954 $\pm$ 0,0143	0,529
Naive Bayes TF-IDF	0,6446	0,6554	0,6451	0,6424	0,6024 $\pm$ 0,0230	0,347

Tempos são os observados nesta execução, em segundos; não são custos de toda a pipeline. DP entre folds não é intervalo de confiança e não demonstra significância estatística.




Figura 1. F1 macro no teste (barras) e média $\pm$ DP em CV-5 (losangos). Esquerda: LDA; direita: Louvain. Figura exportada da execução auditada.

b) Qual abordagem apresentou o melhor desempenho?

No teste LDA, LinearSVC/TF-IDF liderou (F1=0,8336). Em CV LDA, a maior média foi do Naive Bayes/TF-IDF (0,8161), acima de LinearSVC/TF-IDF (0,8091). Para Louvain, k-NN/SBERT liderou tanto no teste (0,7972) quanto na CV (0,7738). Essas posições são descritivas, sem teste de significância.

5. Avaliação — macro-áreas e interpretação

c) Os resultados são satisfatórios?

Como experimento de reprodução de rótulos sintéticos, há sinal aprendível: o melhor modelo LDA acertou 927 de 1.112 exemplos (83,36%); o melhor Louvain acertou 484 de 605 (80,00%). A referência uniforme seria 20% e cerca de 5,56%, respectivamente, mas não foi treinado um DummyClassifier. A avaliação transdutiva e as duplicatas restringem conclusões de generalização. Não se pode interpretar esses números como desempenho diagnóstico.

d) Quais diferenças foram observadas?

Para LDA, LinearSVC/TF-IDF supera LinearSVC/SBERT em aproximadamente 11,43 pontos percentuais de F1 macro; para Louvain, LinearSVC/SBERT supera LinearSVC/TF-IDF em 11,37 pontos. O padrão é compatível com a proximidade entre a representação usada para gerar cada alvo e aquela usada para prevê-lo. Não é evidência de superioridade clínica de uma representação.

e) Quais macroclasses foram mais fáceis ou difíceis?

No melhor modelo LDA, o Tópico 3 teve maior F1 (0,8625) e o Tópico 0, menor (0,7927). Os nomes dos tópicos são rótulos estatísticos; não foram validados por especialistas. A tabela apresenta os valores calculados das predições do teste.

Classe	Precisão	Recall	F1	Suporte
Tópico 0	0,8056	0,7803	0,7927	223
Tópico 1	0,7928	0,8964	0,8414	222
Tópico 2	0,8423	0,8423	0,8423	222
Tópico 3	0,8981	0,8296	0,8625	223
Tópico 4	0,8387	0,8198	0,8292	222




Figura 2. Matriz de confusão do LinearSVC/TF-IDF no teste LDA. Os valores são contagens de exemplos, com rótulo real nas linhas e previsão nas colunas.

5. Avaliação — comunidades Louvain

O melhor modelo nesta tarefa foi k-NN/SBERT. Seus F1 por comunidade variaram de 0,6441 (ID 8) a 0,9014 (ID 6). As associações temáticas abaixo são interpretações das palavras-chave do manifesto, não categorias clínicas validadas.

ID	Perfil temático aproximado	F1	Recall	Suporte
6	Gestação e saúde materna	0,9014	0,9412	34
16	Odontologia e implantes	0,8800	1,0000	33
10	Infecção / tuberculose	0,8615	0,8235	34
8	Cardiovascular	0,6441	0,5758	33
4	Biologia celular / expressão	0,6765	0,6765	34
5	Fígado / oncologia	0,6885	0,6364	33

A comunidade 16 e a comunidade 0 tiveram recall de 1,0, mas precisão inferior a 1,0. Portanto, recuperação completa desses exemplos no teste não equivale a ausência de falsos positivos. Os 18 relatórios por classe estão no pacote.




Figura 3. Matriz de confusão do k-NN/SBERT no teste Louvain. Há 33 ou 34 exemplos por classe. Os IDs correspondem exclusivamente à partição desta execução.

5. Avaliação — análise dos erros

f) Quais confusões ocorreram com maior frequência?

No LinearSVC/TF-IDF para LDA, os maiores pares foram Tópico 0 → 1 (16 casos), Tópico 0 → 4 (15) e Tópico 4 → 0 (15). No k-NN/SBERT para Louvain, os pares 2 → 14, 11 → 16 e 8 → 0 tiveram quatro casos cada. Essas contagens descrevem os erros; sua plausibilidade clínica não foi avaliada por especialistas.

g) O comprimento dos textos está associado aos erros?

No melhor modelo LDA, a taxa de erro cai de 24,8% no quartil mais curto para 10,1% no mais longo. Para Louvain, a sequência não é monotônica: 24,4%, 17,3%, 21,2% e 16,6%. A análise é descritiva e não controla conteúdo, classe ou truncamento do SBERT. Os quartis têm tamanhos diferentes devido aos empates no comprimento.

Tarefa / modelo	Quartil	N	Mediana (palavras)	Taxa de erro
LDA / SVM-TFIDF	1	282	20	24,8%
LDA / SVM-TFIDF	2	276	27	18,1%
LDA / SVM-TFIDF	3	277	168	13,4%
LDA / SVM-TFIDF	4	277	264	10,1%
Louvain / k-NN	1	164	21	24,4%
Louvain / k-NN	2	139	28	17,3%
Louvain / k-NN	3	151	183	21,2%
Louvain / k-NN	4	151	273	16,6%

h) O modelo é adequado para um contexto real de saúde?

Pode ser investigado como apoio exploratório à organização de literatura, com supervisão e avaliação externa. Não está validado para diagnóstico, triagem clínica ou recomendação terapêutica. Erros sobre literatura não foram ponderados por gravidade clínica. A interface admite tradução opcional de PT/ES para inglês, mas esse caminho não foi avaliado nas métricas e envia texto ao serviço de tradução; não devem ser inseridos dados identificáveis de pacientes.

i) O que pode melhorar o experimento?

Priorizar rótulos independentes, idealmente de especialistas ou vocabulários controlados; deduplicar antes da divisão e agrupar textos correlatos; usar uma amostra aleatória e um conjunto externo; corrigir o grafo para similaridade, documentando a mudança; comparar pesos de classe com undersampling; avaliar modelos biomédicos, fine-tuning e, se pertinente, LLMs. Ajustes de hiperparâmetros devem ocorrer somente dentro do treino, com avaliação externa ou aninhada quando necessária.

As dez avaliações e os cinquenta escores de validação cruzada estão vinculados aos mesmos splits e folds registrados no pacote.

6. Reprodutibilidade, limitações e aspectos éticos

Rastreabilidade da execução. O pacote 20261009T051848409288Z.zip registra Python 3.13.16, scikit-learn 1.6.1, NumPy 2.1.3, pandas 2.2.3, SciPy 1.16.3, Sentence-Transformers 5.7.0 e python-louvain 0.16. As demais versões constam em requirements-lock.txt e pip-freeze.txt. O manifesto foi finalizado em 09/10/2026, às 05:20 UTC (02:20 em Fortaleza).

Revisões das fontes. Dataset: a36da4aaaa75a1c0caaba37f5eef7a4f46a4dc4.
Modelo SBERT: 1110a243fdf4706b3f48f1d95db1a4f5529b4d41.

Como repetir. No mesmo ambiente registrado, carregar o ZIP no Colab, executar as definições do Bloco 16A e informar seu caminho em REPLAY_ZIP no Bloco 16B. A comparação reutiliza textos, embeddings, rótulos, splits e folds salvos. Para reconstruir a pipeline inteira, executar os blocos anteriores com as revisões indicadas e a semente 42. Tempos podem variar e não há garantia de identidade entre ambientes diferentes.

Verificação dos resultados. A auditoria conferiu os 105 hashes SHA-256 do manifesto; recalculou acurácia, precisão/recall/F1 macro das dez predições de teste; comparou as dez matrizes de confusão e as médias/desvios dos 50 escores de CV salvos. As checagens foram consistentes. Essa verificação não corresponde a um novo treinamento independente no mesmo ambiente e não autentica, por si só, a origem dos resultados.

Avisos. O arquivo avisos.json contém 12 DeprecationWarnings do SciPy relativos às opções disp/rint no L-BFGS-B usado pela Regressão Logística. Não há ConvergenceWarning registrado nessa comparação. A ausência desse aviso não substitui análise do desempenho ou validação externa.

Limitações metodológicas. (1) LDA/Louvain são ajustados antes do split: o teste participa da definição dos alvos. (2) O Louvain recebe distâncias como pesos, embora pesos altos sejam tratados como conexões fortes. (3) O alvo Louvain deriva da mesma geometria SBERT que os modelos exploram. (4) A amostra inicial não é aleatória e o undersampling descarta dados. (5) Há duplicatas, campos vazios e dois pares duplicados atravessando o split LDA. (6) A CV avalia os classificadores condicionados a rótulos fixos, e não a generalização de todo o processo de construção dos alvos.

Aspectos éticos. O propósito é organização de literatura. Balancear classes temáticas não demonstra equidade demográfica. A revisão humana e a comunicação dos limites são indispensáveis. Houve assistência de IA na implementação do bloco comparativo e na revisão do relatório; a interpretação e a validação pelos autores permanecem necessárias. Não foram empregados LLMs generativos como classificadores no experimento.

Conclusão. Na execução documentada, LinearSVC/TF-IDF alcançou o maior F1 macro no teste LDA (0,8336), e k-NN/SBERT liderou Louvain (0,7972). Na CV LDA, Naive Bayes/TF-IDF apresentou a maior média. O achado central é a interação entre construção do alvo e representação textual; a avaliação mede a reprodução de rótulos sintéticos e não oferece evidência de validade clínica.

Fontes e materiais: enunciado da disciplina; notebook TRABALHO_NLP.ipynb, commit 5269429efbf776d0ebdc39d9025532ea8544cbfb; manifesto, predições, tabelas e figuras do pacote auditado. Fonte de dados: Hugging Face / ruslanmv/ai-medical-dataset.